

大数据实践赛作品报告

在大数据与人工智能技术迅猛发展的推动下，医疗行业正经历一场深层次的数字化变革，从传统经验驱动向数据驱动与智能决策并行的范式快速转型。然而，即便技术变革不断推进，我国医疗体系依然面临“四难困境”的现实瓶颈：一是优质医疗资源区域分布极度不均。《2023 中国卫生健康统计年鉴》显示，城市地区每千人口卫生技术人员数为农村地区的 1.56 倍，东部地区三级医院数量为西部地区的 1.38 倍，叠加偏远地区基础设施薄弱，交通出行不便，形成了长期存在的“看病难”问题；二是广大患者普遍缺乏医学素养。广大患者在面对复杂病症时难以准确判断病因及就医方向，难以匹配专业优势资源，导致显著的信息不对称，进而引发“择院难”的矛盾；三是低收入群体医疗保健支出压力大。农村地区医疗保健支出占消费性支出百分比相比于城市地区高 1.6 个百分点，部分低收入人群发现初期病征时因就医检查、诊疗费用过高，顾虑因病致贫，因病返贫而讳疾忌医的“医资难”现象；四是当前普遍采用的传统分诊流程在效率与精准性方面存在显著短板，尤其在病种分类模糊或病情隐匿阶段，常因误诊与决策延迟错失最佳救治时机，加剧“诊疗难”困境。

针对上述问题，本文提出构建一个面向普通患者与基层医疗需求场景的智能就医决策支持平台。该平台以“精准分诊—智能诊断交互—预后动态评估”的全流程服务为核心理念，综合运用空间地理信息系统（GIS）、医疗大数据分析技术、神经网络建模方法与大语言模型语义理解能力，形成一个覆盖分诊、诊断、评估三大关键环节的闭环式智慧医疗系统。用户可通过关键词输入病症描述，系统实时联动数据库与知识图谱，为用户推荐最佳就医方案，并以可视化地图形式展示推荐医院的地理位置、诊疗特色、交通路径与历史评分等，提升患者就医的可视性与便捷性。

平台内置的智能分诊模块结合了 TextRank 关键词提取算法与前馈神经网络模型，能够对用户的自然语言病情描述进行语义建模与分类决策，从而实现高效、自动化的初步分诊建议。该模块不仅降低了传统人工问诊的时间成本，也显著提升了初诊阶段的准确率。分诊完成后，用户可基于大语言模型开展多轮自然语言对话，获取病因解释、诊疗建议、科普知识甚至心理支持服务，从而弥补患者在

认知、理解与决策层面的短板，强化知情同意与情绪引导的协同效果。

为了进一步提升诊断准确性与平台智能化水平，我们在平台中引入了基于传统机器学习算法拔高后的元学习模型，该模型可应用于结构化病历数据的生存率预测与非结构化医学图像的智能分析。通过任务级别的快速适应与模型泛化能力提升，元学习模型能有效识别疾病发展趋势，辅助医生及患者做出更具前瞻性的治疗决策。此外，为了实现更强的个体化预测效果，我们进一步引入终身学习机制，通过动态调整惩罚函数与模型扩展结构，使系统具备随用户历史行为不断演化的能力，从而真正实现“千人千面”的自适应预测服务。

与此同时，平台还自动记录用户每一次的交互过程与模型预测结果，并生成个体化病情趋势图及可视化健康分析报告，帮助用户系统性地追踪自身病情变化、识别关键节点、优化治疗路径。特别是对于需要长期随访的复诊患者与慢性病管理人群，该模块可作为辅助决策工具，为医生提供科学依据，也为患者提供治疗路径与依从性的可量化支撑，进而有效降低重复检查、过度治疗与资源浪费的发生率，推动治疗方案向数据驱动与精细化方向发展。

问题分析

问题来源

随着社会经济的不断发展，人们对卫生健康的需求不断提高。2016年10月25日中共中央、国务院印发了《“健康中国2030”规划纲要》，2017年10月18日，习近平同志在十九大报告中提出了健康中国发展战略，2023年全国卫生总费用初步核算为90575.8亿元，人均卫生总费用6425.3元，卫生总费用占GDP的比例为7.2%，基本医疗保险参保率超过95%，基本实现全民覆盖。我国人均预期寿命达到78.6岁，孕产妇死亡率下降到15.1/10万，婴儿死亡率下降到4.5‰，均为历史最好水平。人民群众健康水平得到持续提升，卫生健康事业高质量发展取得新进步。然而，从空间分布的角度看，沿海地区与内陆地区，城镇地区与农村地区，经济发达地区与经济欠发达地区相比，人均医疗卫生支出，人均医疗卫生机构与人员等各项卫生健康发展指标均有较大的差异，我国的卫生健康事业存在着不平衡不充分发展的问题。部分偏远地区，贫困地区的医疗卫生机构数量与医疗卫生服务质量显著落后于平均水平。受限于社会经济发展水平与地理条件，这些地区长期以来通过简单的增加政府公共卫生投入的“大水漫灌”的方法无法彻底改变卫生健康事业的落后面貌。随着互联网与信息技术的高速发展，偏远地

区的信息基础设施逐步建成、完善，从业人员发现，互联网，5G 通信，人工智能等现代信息技术构建的桥梁可以弥补偏远地区在地理上的先天劣势，跨越时空限制，把先进的医疗卫生服务带到偏远地区，进一步提升医疗卫生服务的公平性与普惠性。

现有解决方案

经过多年的发展，现在市面上已经有了一些互联网+医疗的产品，我们把它们分为两类进行讨论。第一类是浏览器接入的在线健康咨询助手。用户在浏览器中输入某类疾病时，浏览器首先输出该疾病的百科，简单介绍其病因、症候和治疗方案，随后可以点击跳转在线真实医生问诊平台，这些医生按职称分等级收取在线咨询费用，用户输入简单的（10-50 字）的症状描述进行付费咨询。第二类是互联网+家庭医生。通常，家庭医生服务平台提供多种服务组合包，用户付费签约后可以获得定期上门体检，线上问诊服务，针对行动不便的老人与小孩，家庭医生提供上门问诊与用药指导服务。

本作品要解决的痛点问题

上述两类产品都有一些共同的缺点。一、付费咨询。现有线上问诊服务根据医生经验与服务范围，收取不等的费用。对于偏远地区与贫困地区的中低收入人群，医疗支出是非常敏感的。特别是贫困地区家庭经济压力比较大的中老年人，在身体出现不适时往往因为害怕因病致贫，因病返贫而不愿意前往医院进行初步检查，导致病情持续恶化，拖到病症严重影响生活乃至生存时才前往医院进行治疗，在身心长期遭受病痛折磨的同时，可能还增加了治疗难度与费用，人财两失。我们项目通过搭建一个基于深度学习与自然语言模型的问诊智能体，优化人工支出，提供免费、开放的医疗问诊服务，免除贫困人群求医问诊的后顾之忧。我们通过深度学习算法进行疾病预测，将疾病发现在早期，以期实现早问诊，早发现，早治疗，早痊愈。二、无法对复杂疾病的早期模糊症状进行识别。对于一些复杂的疾病的早期症状，线上问诊难以分辨，容易误诊、漏诊，错过治疗的黄金时间。我们的智能模型可以根据用户提供的年龄、性别、地区、生活习惯、过往病史、家族病史、早期症状等多维数据，通过算法分析数据与疾病的相关性，预测用户患病的概率，以进行进一步的问诊与治疗建议。

三、

解决问题的思路

我们将产品部署到网站上。用户在前端向智能体描述自己的大致症状时，基于 textrank 智能分诊系统会将文本形式的症状描述转化为特征值，与模型中各类疾病的数据进行匹配，判断其可能患有疾病的类型。随后，系统调用相应的疾病模型，向用户详细问诊，获取性别、年龄、身高、体重、地区、家族病史等一系列信息，使用基于 Meta Learning（元学习）、Few-shot Learning（少样本学习）与 Lifelong Learning（终身学习技术）的模型分析数据组成与数据相关性，评估用户患有该类疾病的概率。如若模型预测用户患病的概率较高，系统调用相应的疾病资源库为用户提供详细的诊断分析与治疗建议，并生成医疗地图，显示用户所在地区该类疾病治疗水平较高的医院的信息。面向医疗水平相对较低，医学影像判断经验不足的偏远地区，用户就近在低级别医疗机构就医，经过医学检验取得医学影像资料后，上传至智能体，基于 Yolo11n 的医学图像识别算法可以标注病灶并判断疾病的医学等级，进而做出诊断。脑肿瘤数据集、结直肠癌数据集、乳腺癌数据集、肺癌数据集、乳腺癌图像预测集来自 kaggle 公开数据集；分诊症状数据集来自 Github 病症数据集；脑肿瘤预测集来自 YOLOV11 官网脑肿瘤数据集，数据格式为 csv、jpg。

第一章 技术方案

首先提供基于地图的医院推荐功能，根据用户所关注的癌症类型，通过调用高德地图的 API 在地图上直观查找各地区的优质医疗资源。接着，根据用户是否知晓自身病情进行初步分流：对于尚不清楚病情的用户，平台通过其输入的症状特征，结合 Textrank 模型提取关键词，并使用前馈神经网络进行智能分诊，初步识别可能涉及的癌症类型；而对于已知病情的用户，则可直接跳转至相关癌症的深度分析模块。

在完成初步分诊后，平台将引导用户进入五大核心功能模块：**专业建议**模块整合权威医学资料与专家共识，为用户提供可参考的医疗意见；**大模型医生**模块基于 DeepSeek API，并采用 Few-shot Learning 技术，借助大语言模型生成具备专业水平的个性化诊疗建议；**预测模型**模块采用两阶段建模策略：第一阶段分别构建不同癌症的基础模型，医学影像数据通过 YOLOv11 实现高精度病灶检测与分级评估，结构化临床数据则通过多维特征工程，独立训练 13 种机器学习模型；第二阶段基于模型表现进行元学习优化，并结合用户反馈引入终身学习机制，持续调整惩罚函数和模型结构，实现“千人千面”的个性化预测；**数据分析模块**，用于深入解析不同特征数据之间的组成结构与相关性，展示模型训练与预测过程中关键特征的贡献度，评估各类模型在不同数据维度下的性能表现；**历史记录与**

可视化模块支持用户查看与大模型医生的完整交互记录，并通过交互式图形界面，动态展示健康状态演变趋势与历史预测结果




图 1 技术思路图

1.1

1.1 YOLO 算法

◆ 核心思想：

将目标检测统一为一个单阶段回归问题，直接在单个神经网络中预测边界框和类别概率。通过将图像划分为网格，每个网格单元回归出目标的位置、置信度和类别，最后通过非极大值抑制（NMS）输出最优检测结果，实现高效且端到端的检测。

◆ 原理：

首先将输入图像均匀划分为 $S \times S$ 的网格结构，每个网格单元 G_{ij} 通过预测函数 $f_{\text{pred}}()$ 生成 B 个边界框的几何参数和置信度：

$$\mathbf{b}_{ij} = f_{\text{pred}}(G_{ij}) = (x_{ij}, y_{ij}, w_{ij}, h_{ij}, c_{ij}) \quad \text{式 (4-1)}$$

其中 (x,y) 表示中心点相对网格的归一化偏移量， (w,h) 为相对于整图的宽高比例， c 为框内存在目标的置信度。同时每个网格输出 C 个类别的条件概率分布：

$$\mathbf{p}_{ij} = (p_{ij}^1, \dots, p_{ij}^C) \quad \text{式 (4-2)}$$

系统通过置信度与最大类别概率的乘积计算最终检测得分：

$$\text{Score}_{ij} = c_{ij} \times \max_c p_{ij}^c \quad \text{式 (4-3)}$$

基于该得分和预设阈值，初步筛选出的检测框通过非极大值抑制(NMS)算法去除冗余结果，保留 IoU 重叠度小于阈值 θ 的最高分检测框：

$$\mathcal{D}_{\text{final}} = \{\mathbf{b}_k \mid \text{IoU}(\mathbf{b}_k, \mathbf{b}_m) < \theta, \forall \text{Score}_k > \text{Score}_m\} \quad \text{式 (4-4)}$$

最终所有检测结果与类别标签、置信度等元数据封装为结构化输出：

$$\text{Output} = (\mathbf{b}_k, \text{cls}_k, \text{Score}_k, \text{timestamp}) \quad \text{式 (4-5)}$$

1.2 基础模型库选的机器学习模型

◆ 基础模型库的机器学习算法：

逻辑回归：

用于二分类问题的概率预测模型，通过 Sigmoid 函数将线性组合转换为概率：

$$P(y = 1|x) = \frac{1}{1 + e^{-(w^T x + b)}} \quad \text{式 (4-44)}$$

✧ 随机森林回归:

用于回归任务的集成学习方法，通过多棵决策树预测的平均值提高稳定性:

$$y = \frac{1}{K} \sum_{k=1}^K T_k(x) \quad \text{式 (4-46)}$$

✧ 线性回归:

用于连续值预测的基础模型，通过最小化平方误差拟合线性关系:

$$y = w^T x + b \quad \text{式 (4-47)}$$

✧ 决策树:

用于分类和回归的非参数模型，通过递归划分特征空间构建预测规则:

$$\text{Gain}(D, A) = H(D) - \sum_v \frac{|D_v|}{|D|} H(D_v) \quad \text{式 (4-49)}$$

$$\text{其中 } H(D) \text{ 为熵: } - \sum p \log p. \quad \text{式 (4-50)}$$

✧ 支持向量机:

用于分类和回归的最大间隔模型，通过核函数处理非线性可分数据:

$$\min_w \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w^T x_i + b) \geq 1 \quad \text{式 (4-51)}$$

✧ 朴素贝叶斯:

用于文本分类等任务的概率模型，基于特征条件独立假设:

$$P(y|x) \propto P(y) \prod_{i=1}^n P(x_i|y) \quad \text{式 (4-52)}$$

✧ 梯度下降:

用于优化模型参数的迭代算法，沿负梯度方向更新参数:

$$w := w - \eta \nabla_w J(w) \quad \text{式 (4-53)}$$

$$\text{其中 } \eta \text{ 为学习率, } \nabla_w J(w) \text{ 为梯度。} \quad \text{式 (4-54)}$$

◇ 弹性网络回归:

用于高维数据回归的正则化方法, 结合 L1 和 L2 惩罚项:

$$J(w) = \|y - Xw\|^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2 \quad \text{式 (4-55)}$$

◇ LASSO 回归:

用于特征选择的回归方法, 通过 L1 正则化产生稀疏解:

$$J(w) = \|y - Xw\|^2 + \lambda \|w\|_1 \quad \text{式 (4-56)}$$

◇ 多层感知机 (MLP):

用于复杂模式识别的神经网络模型, 通过多层非线性变换实现:

第 1 层输出:

$$h_l = \sigma(W_l h_{l-1} + b_l), \quad \sigma(z) = \max(0, z) \quad \text{式 (4-57)}$$

输出层 :

$$P(y|x) = \text{softmax}(W_L h_{L-1} + b_L) \quad \text{式 (4-58)}$$

◇ 多项式回归:

用于非线性关系的回归方法, 通过多项式基扩展特征

$$y = w^T \phi(x) + b, \quad \phi(x) = [x, x^2, \dots, x^d] \quad \text{式 (4-59)}$$

◇ 岭回归:

用于共线性数据回归的正则化方法, 通过 L2 惩罚稳定解

$$J(w) = \|y - Xw\|^2 + \lambda \|w\|_2^2 \quad \text{式 (4-60)}$$

1.3 基于 Prompt Engineering 对大语言模型回答的改进

◆ 理论依据:

Brown 等人(2020)在《Language Models are Few-Shot Learners》中的研究表明, 少样本学习(Few-shot Learning)能显著提升语言模型的性能表现。通过引入自然语言任务描述和少量示例(K=10-100), 模型在不同任务中

展现出明显的性能提升，且这种提升与模型规模及上下文示例数量呈正相关。同时研究也发现，模型仅需单样本(1-shot)就能学习任务，而增加示例数量(3-shot/5-shot 等)可进一步优化表现，特别是对复杂任务效果显著。这种基于上下文学习的方法不仅大幅降低了特定任务的数据需求，避免了传统微调可能导致的分布偏差问题，而且完全不需要参数更新或微调过程，展现了强大的零样本迁移能力。




图5 few-shot learning框架

◆ 改进措施：

在医疗健康领域，特别是针对脑肿瘤、结直肠癌、胃癌、乳腺癌这些重大疾病的诊断和咨询场景，患者和医生对 AI 模型的回答有着极高的要求，需要同时保证准确性、严谨性和可解释性。然而，当前通用大语言模型（LLM）在实际应用中存在明显不足：首先，模型可能产生缺乏医学依据的推测性内容，甚至出现误导性回答；其次，回答结构往往松散混乱，未能遵循“病因→症状→治疗建议”的标准医学逻辑；最重要的是，由于缺少权威文献或临床指南的支持，其可信度难以满足专业医疗工作者的需求。

为解决这些问题，我们创新性地设计了一套基于 Few-shot Learning 的标准化输出模板，通过三重约束机制确保回答的科学性：首先明确角色定位，通过固定提示词限定回答的专业视角；其次构建结构化输出模板，严格规范回答的逻辑链条；最后通过注入 5-10 组高质量示例，确保术语规范、逻辑连贯并符合标准文献引用格式。

1.4 基于 YOLO 的图像检测和直接预测的多模态预测

◆ 缘由：

在医疗健康领域，脑肿瘤、结直肠癌、胃癌和乳腺癌等重大疾病的精准预测对临床决策至关重要，直接影响治疗方案的选择和患者预后。因此，

医疗诊断对预测模型的准确率提出了极高要求。

然而，传统单一预测模式存在明显的理论局限和实践缺陷：YOLO 算法虽然能够高效定位病灶区域，其分类性能却受限于浅层网络结构，对复杂病理特征的判别能力约束在线性决策边界内：

$$P(y|x) = \sigma(w^T x + b) \quad \text{式 (4-1)}$$

而基础模型库中的单一独立机器学习模型（如逻辑回归、SVM 等）虽然在特定数据分布下表现良好，但由于医学数据的异质性和疾病特征的复杂性，单一模型的泛化误差：

$$\epsilon_{gen} = \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathcal{L}(y, f(x))] \quad \text{式 (4-2)}$$

往往超出医学上可接受的阈值范围。

◆ 改进措施

为此，我们构建了动态多模态预测框架。

患者临床特征向量为：

$$\mathbf{x} \in \mathbb{R}^d \quad \text{式 (4-1)}$$

通过基础模型库 $M = \{\text{逻辑回归}, \text{随机森林}, \dots, \text{元学习}\}$ 生成多视角预测结果，模型选择依据其在目标病症上的综合效能评分：

$$S_m = \underbrace{0.4 \cdot F1_m}_{\text{平衡精度}} + \underbrace{0.3 \cdot AUC_m}_{\text{区分度}} + \underbrace{0.3 \cdot (1 - \text{Brier}_m)}_{\text{校准性}} \quad \text{式 (4-2)}$$

其中：

$$F1_m = 2 \cdot \frac{\text{Precision}_m \cdot \text{Recall}_m}{\text{Precision}_m + \text{Recall}_m} \quad \text{式 (4-3)}$$

$$\text{Brier}_m = \frac{1}{N} \sum_{i=1}^N (p_m^{(i)} - y^{(i)})^2 \quad \text{式 (4-4)}$$

通过贪心算法筛选最优的 3 个模型子集：

$$\mathcal{M}_{\text{selected}} = \arg \max_{|\mathcal{M}'|=3} \sum_{m \in \mathcal{M}'} S_m \quad \text{式 (4-5)}$$

对输入图像：

$$\mathbf{I} \in \mathbb{R}^{H \times W \times C} \quad \text{式 (4-6)}$$

通过深度卷积网络提取多尺度特征：

$$\phi_{\text{CNN}}(\mathbf{I}) = \text{ConvBlock}_5(\text{ConvBlock}_4(\dots \text{ConvBlock}_1(\mathbf{I}))) \quad \text{式 (4-7)}$$

并生成病症概率分布：

$$P_{\text{YOLO}}(y|\mathbf{I}) = \text{softmax}(\mathbf{W}_c \cdot \text{GAP}(\phi_{\text{CNN}}(\mathbf{I}))) \quad \text{式 (4-8)}$$

其中： $\text{GAP}(\cdot)$ 为全局池化操作， $\mathbf{W}_c \in \mathbb{R}^{K \times D}$ 为分类层权重矩阵。

然后设置置信度加权机制，平衡各模型预测可靠性。定义温度调节的权重分配函数：

$$w_m = \frac{\exp(T \cdot C_m)}{\sum_{m'} \exp(T \cdot C_{m'})}, \quad \text{式 (4-9)}$$

$$C_m = 1 - \underbrace{\sum_{k=1}^K P_m(y = k|\mathbf{x}) \log P_m(y = k|\mathbf{x})}_{\text{熵值计算}} \quad \text{式 (4-10)}$$

温度系数 T 根据验证集调整，当 $T \rightarrow 0$ 时权重均匀分布， $T \rightarrow +\infty$ 时聚焦最高置信度模型。然后进行多模态概率融合，集成结构化数据与图像模态的预测结果：

$$P_{\text{final}}(y|\mathbf{x}, \mathbf{I}) = \sum_{m \in \mathcal{M}_{\text{selected}}} w_m P_m(y|\mathbf{x}) + w_{\text{YOLO}} P_{\text{YOLO}}(y|\mathbf{I}) \quad \text{式 (4-11)}$$

决策阈值 τ 通过 PR 曲线分析确定，满足：

$$\hat{y} = \begin{cases} 1 & \text{if } P_{\text{final}}(y = 1) \geq \tau \\ 0 & \text{otherwise} \end{cases} \quad \text{式 (4-12)}$$

最后，为了保证预测的安全可靠，设置安全验证机制。当模型间 KL 散度超过阈值时触发人工复核，来有效控制误诊风险。

$$\Delta = \frac{1}{4} \sum_{m \neq m'} D_{\text{KL}}(P_m \| P_{m'}), \quad \text{若 } \Delta > \tau_{\text{alert}} \text{ 则启动专家会诊} \quad \text{式 (4-13)}$$